

# بررسی الگوریتم‌های Deepwalk و Node2Vec در سامانه‌های توصیه‌گر



استاد راهنما: سرکار خانم دکتر بیتا شمس

مردادماه ۱۳۹۹

# فهرست

۲

الگوریتم‌ها

۱

مقدمه

۱۴

ارزیابی

۱۳

تعاریف

# مقدمه

سامانه‌ها یا موتورهای توصیه‌گر با بررسی و تحلیل رفتار کاربران مناسب‌ترین اقدام چون فیلم، کاذو... رایده آن‌ها پیشنهاد می‌کنند. حجم روزافزون اطلاعات، توجه هرچه بیشتر پژوهشگران رایده این سامانه‌ها معطوف داشته است تا با ارائه الگوریتم‌هایی بهینه‌تر بتوانند در دستیابی کاربران به هدفشان آن‌ها را یاری کنند. گراف‌ها که شبکه‌های اجتماعی، خطوط حمل و نقل و... نمایندگان آن‌ها در زندگی حقیقی هستند به کمک پژوهشگران در این زمینه شناخته‌اند.

مدل سازی به وسیله گراف به پژوهشگران کمک می کند تا به ترک بهتری از کاربران، محصولات و روابط بین آن ها در یک سامانه دست یابند. کاربران و محصولات، خود هر کدام نماینده یک گره منحصر به فرد در گراف متناظر با سامانه هستند و روش های متعددی تا به امروز برای بررسی ساختار حاکم بر روابط میان آن ها ارائه شده است. به طور کلی این روش ها در چهار دسته مختلف جای می گیرند که عبارت اند از :

## ۱. Node Classification

## ۲. Link Prediction

## ۳. Clustering

## ۴. Visulization

روش شماره ۱ در صدد یافتن برجسب گره ها با توجه به برجسب گره های موجود و توپولوژی شبکه است. روش شماره ۲ در صدد یافتن روابطی بین گره ها است که می توانند در آینده رخ دهند. روش شماره ۳ در صدد یافتن گره های مشابه و انجام آن ها به عنوان یک گروه است و در انتها روش شماره ۴ در صدد فراهم آوردن بینشی برای فهم ساختار حاکم بر شبکه است. در چند دهه اخیر پژوهش های زیادی در این زمینه شکل گرفته است اما آنچه که به تازگی توجه محققان را به خود جلب کرده است الگوریتم هایی است که از نمایش گره های گراف در فضایی برداری استفاده می کنند. تلاش های صورت گرفته در بهبود الگوریتم های موجود در روش اول سبب ایجاد الگوریتم هایی با عنوان **Random Walk** گشته است که از جمله الگوریتم های نامبرده هستند.

# الگوریتم‌ها

همانطور که گفته شد الگوریتم‌های Random Walk الگوریتم‌هایی هستند که با استفاده از نمایش گره‌های گراف در فضایی برداری سعی در پیشنهاد مناسب‌ترین اقدام به کاربران دارند. این الگوریتم‌ها زمانی به کار می‌آیند که شبکه به قدری بزرگ است که نمی‌توان به طور کامل آن را ذخیره نمود و تنها امکان مشاهده بخشی از آن فراهم است. اساس کار این الگوریتم‌ها یافتن مسیرهایی تصادفی با شروع از یک گره و انتخاب گرهی بعدی با احتمالی معین است.



دو نوع از مهم ترین و معروف ترین انواع این الگوریتم ها عبارتند از:

**Deepwalk**

**Node2Vec**

## الگوریتم Deepwalk

گراف  $G=(V, E)$  با مجموعه رئوس  $V$  و مجموعه یال‌های  $E$  را در نظر بگیرید. در شروع، الگوریتم درختی شونده‌یی از  $G$  می‌سازد و با انتخاب راسی چون  $W_i$  از مجموعه رئوس به طور تصادفی روند را ادامه می‌دهد. راس بعدی را این مسیر تصادفی از میان رئوس همسایه  $W_i$  انتخاب می‌گردان و الگوریتم خود را توجه به آرگومان‌هایی مختلف بیشترین احتمال را برای انتخاب هریک از رئوس همسایه محاسبه می‌کند. هدف نمایش هر گره از بردار در فضای برداری  $R^d$  است بنابراین به ازای هر گره در گراف، مسیری تصادفی توسط الگوریتم طی می‌شود و در هر مرحله نمایش گراف به‌روز می‌شود.

## الگوریتم Node2Vec

این الگوریتم بسیار شبیه به الگوریتم قبلی عمل می‌کند. تفاوت عمده آن با الگوریتم قبلی در بکارگیری استراتژی‌های کانسیک جستجو یعنی دو الگوریتم جستجوی اول سطح و جستجوی اول عمق در انتخاب رئوس مسیر تصادفی است. همین امر سبب می‌شود تا بردار متناظر با هر گره در گراف از کیفیتی بالاتر برخوردار باشد و جزئیات اطلاعاتی بیشتری از گراف را در اختیار داشته باشد.



در پایان هر دو الگوریتم با استفاده از Stochastic Gradient Descent و تعیین ضریب یادگیری مناسب بردارها را بهینه می کنند.

تفاوت هر گره از گراف با یک بردار خود، کاری دشوار است اما آنچه پیاده سازی این دو الگوریتم را چالش برانگیز می کند سه موضوع است:

۱. تعداد مسیرهای تصادفی

۲. طول مسیرهای تصادفی

۳. طول بردار

طول بردار مهمترین بخش است چرا که در نمایش جزئیات اطلاعاتی گراف نقشی تعیین کننده دارند. نکته حائز اهمیت بعدی تعداد مسیرهای تصادفی است. با توجه به بزرگ بودن شبکه، اجرای این دو الگوریتم به توان محاسباتی بسیار بالایی نیاز دارند و هر چند افزایش تعداد مسیرهای تصادفی معیارهای ارزیابی را افزایش می دهد اما محتاج توان محاسباتی به مراتب بیشتری است پس مطلوب است با وسواس تعیین گردند.

هر دو الگوریتم به صورت کتابخانه در زبان Python قابل استفاده هستند. برای استفاده کافی است آن ها را نصب کنید. در documentation هر دو الگوریتم نحوه نصب آن ها در سیستم عامل های مختلف ذکر شده است.





ورودی‌های هر دو الگوریتم شامل گراف یا لیست مجاورت یا لی گراف، تعداد مسیرهای تصادفی، طول مسیرهای تصادفی و طول بردار است.

الگوریتم `deepwalk` از طریق دستورهای `command` در `Anaconda Prompt` اجرا می‌شود. کافی است یک فایل با پسوند `.adjlist` در `path` که شامل لیست مجاورت یا لی گراف است و فایلی با پسوند `embeddings` جهت دریافت بردارها قرار دهید. با اجرای `command` زیر الگوریتم اجرا خواهد شد.

```
deepwalk --input file.adjlist --number-walks 200 --representation-size  
10 --walk-length 5 --window-size 10 --output file.embeddings
```

برای اجرای الگوریتم `node2vec` بر روی داده‌ها اما نیازی به کمی کدنویسی است. پس از `import` کتابخانه مربوطه در برنامه باید با ساختن `object` از کلاس `node2vec` ورودی‌ها را به آن داده و مدل را بسازید. باید مدل را در فایلی با پسوند `emb` ذخیره نمایید.

# تعاریف

برای اجرای دو الگوریتم از مجموعه داده Movie Lenz استفاده می‌کنیم. این مجموعه داده شامل ۱۰۰ هزار نمونه داده از میان ۹۴۳ کاربر و ۱۶۸۲ فیلم است. هر کاربر به فیلم‌هایی که تماشا کرده امتیازی از ۱-۵ داده است. هدف پیشنهاد فیلم‌هایی به هر کاربر با استفاده از دو الگوریتم ذکر شده و با در نظر گرفتن فیلم‌هایی است که تماشا کرده است. ابتدا فیلم‌هایی را انتخاب می‌کنیم که امتیاز بیشتر از ۴ از سوی کاربران دریافت کرده‌اند. به این ترتیب فیلم‌هایی در فاز یادگیری انتخاب می‌شوند که مورد توجه بیشتری از سوی هر کاربر بودند و در روند پیشنهاد بهتر به هر کاربر هار را یاری می‌کنند.



هر نمونه از این داده شامل سه بخش مختلف است. به طور مثال:


۲ ۱۱۸۱۴ ۲۴۳۳

این نمونه بیان می کند که کاربر شماره ۲۴۳۳ به فیلم ۱۱۸۱۴ امتیاز ۲ داده است. همانطور که اشاره شد اولین قدم در فاز یادگیری غربالگری فیلم های تماشا شده است که امتیاز بیشتری یا مساوی ۴ از سوی هر کاربر دریافت کرده است.

پیش از آن یک نکته قابل توجه است و آن اینکه کاربرها و فیلم ها هر دو از ۱ شماره گذاری شده اند و دو مجموعه شماره ها در بخشی مهم پوشانی دارند. بنابراین، باید یک Mapping صورت گیرد به این شکل که فیلم ها از ۹۱۴ تا ۲۶۲۵ شماره گذاری گردند.

پس از تحقق امر بالا، یک ماتریس  $۲۶۲۵ \times ۹۱۴$  در نظر می گیریم. با بررسی هم زمان مجموعه داده ها و ماتریس مفروض، چنانچه کاربری به فیلمی امتیاز بیشتری یا مساوی ۴ داده بود در خانه متناظر با سطر و ستون مربوطه ۱ و در غیر این صورت ۰ قرار می دهیم

واضح است که گراف شبکه مورد نظر یک گراف دو بخشی است و گره های یک بخش شامل کاربران و بخش دیگر شامل فیلم ها هستند. در اینجا نقت کنید که این گراف جهت دار نیست چرا که در صورت جهت دار بودن سر هر یال یک فیلم و دم آن یک کاربر را نشان می داد و برعکس. بدین گونه دوری میان دو بخش گراف موجود نبوده، برخی روابط از بین رفته و الگوریتم غیر قابل اجرا می بود.



حال ما ماتریس مجاورت این گراف دو بخشی را در اختیار داریم ولی ورودی هر دو الگوریتم نیست مجاورت یالی است. به آسانی می توان لیست مجاورت یالی را با استفاده از ماتریس مجاورت به دست آورد. به این صورت که در هر سطر از ماتریس مجاورت خانه هایی با مقدار ۱ وجود دارند و بیانگر وجود یک یال بین دو سرگره ها هستند.

در قدم بعدی از فاز یادگیری برای هر کاربر داده آموزش و آزمون را با استفاده از ابزارهای کتابخانه Sklearn و نسبت ۸۰٪-۲۰٪ جدا می کنیم. این دو دسته هر یک بیانگر زیرگرافی اقلایی از گراف اصلی هستند و وقت کنید که باید ذخیره شوند چرا که هر دو الگوریتم باید چند مرتبه روی آن ها اجرا شوند. با داشتن لیست مجاورت یالی زیرگراف داده آموزش می توان الگوریتم **deepwalk** را به ترتیب گفته شده اجرا نموده ولی برای اجرای الگوریتم **node2vec** برخلاف آن نیاز به خود زیرگراف داریم. در اینجا است که با استفاده از کتابخانه **Networkx** و با داشتن لیست مجاورت یالی، زیرگراف را از روی آن ساخته و برای اجرا آماده می کنیم.

با اجرای دو الگوریتم بر روی داده آموزش فاز یادگیری پایان می یابد و بردارهای متناظر با هر گره از گراف را در ادامه از ضرب کسینوسی و ضرب داخلی برای تعیین میزان شباهت بردارها استفاده می کنیم.

ضرب داخلی و ضرب کسینوسی دو بردار غیر صفر به ترتیب به طرق زیر تعریف می شوند:

$$\mathbf{A} \cdot \mathbf{B} = \|\mathbf{A}\| \|\mathbf{B}\| \cos \theta$$

$$\text{similarity} = \cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|}$$

هر قدر ضرب کسینوسی و ضرب داخلی دو بردار بیشتر باشد میزان شباهت آن ها بیشتر خواهد بود پس کافی است برای هر کاربر در شبکه، بردار متناظرش را در بردار فیلم هایی که در داده آموزش نبوده اند ضرب کنیم و مقادیرش را مرتب نماییم. به این ترتیب فیلم های پیشنهادی به ازای هر کاربر تعیین می گردند و وقت آن می رسد که Mapping را خنثی سازیم و بر حسب هر فیلم را از بازه ۱۶۸۲-۹۱۴۴ به بازه ۱-۱۶۸۲ باز گردانیم.

فاز آزمون را با انتخاب  $n$  فیلم از فیلم های پیشنهادی به ازای هر کاربر آغاز می کنیم. برای هر کاربر آن ها را با داده آزمون که از قبل جدا کرده ایم مقایسه می کنیم.

## معیارهای ارزیابی

**Precision** برای هر کاربر تقسیم اشتراکات داده آزمون و فیلم‌های پیشنهادی بر  $n$  تعریف می‌شود و برای مجموعه داده به صورت میانگین precision تمام کاربرها.

**Recall** برای هر کاربر تقسیم اشتراکات داده آزمون و فیلم‌های پیشنهادی بر تعداد داده‌های آزمون تعریف می‌شود و برای مجموعه داده به صورت میانگین Recall تمام کاربرها.

**F1** برای هر کاربر به صورت  $\frac{1}{2}$  برابر تقسیم حاصل ضرب بر حاصل جمع Precision و Recall آن کاربر تعریف می‌شود و برای مجموعه داده‌ها به صورت میانگین F1 تمام کاربرها.

**NDCG** برای هر کاربر به صورت تقسیم DCG بر IDCG و برای مجموعه داده‌ها به صورت میانگین NDCG تمام کاربرها تعریف می‌شود.

**1-Call** برای هر کاربر چنانچه تعداد اشتراکات داده آزمون و فیلم‌های پیشنهادی حداقل 1 باشد، 1 و در غیر این صورت 0 تعریف می‌شود و برای مجموعه داده به صورت میانگین 1-Call تمام کاربرها.



با انتخاب پارامترهای زیر و معیار شباهت مورد نظر، هر الگوریتم را به مرتبه اجرا می‌کنیم:


**Number of walks = 200**

**length of walk = 5**

**dimension = 10**

**$n = \{ 20, 50, 100 \}$**





deepwalk algorithm & inner product  
number of walks = 200  
length of walk = 5  
dimension = 10  
n = 20

	1	2	3	4	5	Mean
Precision	0.0026	0.003	0.0025	0.0027	0.003	0.00276
Recall	0.005	0.0071	0.006	0.006	0.0075	0.00632
F1	0.003	0.0038	0.0031	0.0032	0.0038	0.00338
NDCG	0.1525	0.1527	0.1523	0.1525	0.1525	0.1525
I-Call	0.0509	0.0593	0.0509	0.054	0.0583	0.05468



deepwalk algorithm & cosine similarity


number of walks = 200

length of walk = 5

dimension = 10

n = 20

	1	2	3	4	5	Mean
Precision	0.0266	0.0268	0.0273	0.027	0.0282	0.02718
Recall	0.0835	0.0861	0.0851	0.0855	0.0907	0.08618
F1	0.0364	0.037	0.0375	0.0371	0.0391	0.03742
NDCG	0.1549	0.1538	0.1539	0.1547	0.1546	0.15438
I-Call	0.3806	0.3775	0.3891	0.3806	0.3891	0.38338



node2vec algorithm & inner product  
number of walks = 200  
length of walk = 5  
dimension = 10  
n = 20

	1	2	3	4	5	Mean
Precision	0.0021	0.0019	0.0022	0.0023	0.0018	0.00206
Recall	0.0077	0.006	0.008	0.0077	0.0062	0.00712
F1	0.0031	0.0026	0.0032	0.0032	0.0025	0.00292
NDCG	0.1516	0.152	0.1518	0.1517	0.1519	0.1518
I-Call	0.0413	0.0381	0.0445	0.0445	0.0371	0.0411



node2vec algorithm & cosine similarity


number of walks = 200

length of walk = 5

dimension = 10

n = 20

	1	2	3	4	5	Mean
Precision	0.0009	0.0007	0.0007	0.0006	0.0007	0.00072
Recall	0.0032	0.0025	0.0026	0.0026	0.003	0.00278
F1	0.0013	0.0011	0.0011	0.001	0.0011	0.00112
NDCG	0.1517	0.1516	0.1516	0.1514	0.1514	0.15154
I-Call	0.019	0.0159	0.0159	0.0137	0.0148	0.01586



deepwalk algorithm & inner product  
number of walks = 200  
length of walk = 5  
dimension = 10  
n = 50

	1	2	3	4	5	Mean
Precision	0.0048	0.0047	0.0046	0.0048	0.0045	0.00468
Recall	0.0303	0.0317	0.0294	0.0312	0.295	0.08352
F1	0.0076	0.0075	0.0074	0.0077	0.0072	0.00748
NDCG	0.01	0.01	0.01	0.0099	0.0099	0.00996
I-Call	0.1919	0.1887	0.1866	0.1876	0.1834	0.18764



deepwalk algorithm & cosine similarity


number of walks = 200

length of walk = 5

dimension = 10

n = 50

	1	2	3	4	5	Mean
Precision	0.0271	0.0266	0.0277	0.0275	0.0281	0.0274
Recall	0.1903	0.1885	0.1933	0.1949	0.196	0.1926
F1	0.044	0.0432	0.045	0.0448	0.0455	0.0445
NDCG	0.0103	0.01	0.0102	0.0101	0.0102	0.01016
I-Call	0.6648	0.6405	0.6712	0.6765	0.6776	0.66612



**node2vec algorithm & inner product**  
**number of walks = 200**  
**length of walk = 5**  
**dimension = 10**  
**n = 50**

	1	2	3	4	5	Mean
Precision	0.0024	0.0023	0.0023	0.0023	0.0023	0.00232
Recall	0.019	0.0179	0.0182	0.0188	0.0194	0.01866
F1	0.0039	0.0038	0.0038	0.0039	0.0039	0.00386
NDCG	0.0098	0.0098	0.0097	0.0097	0.0097	0.00974
I-Call	0.1049	0.1039	0.1028	0.1028	0.1028	0.10344





node2vec algorithm & cosine similarity


number of walks = 200

length of walk = 5

dimension = 10

n = 20

	1	2	3	4	5	Mean
Precision	0.0008	0.0009	0.0009	0.0009	0.001	0.0009
Recall	0.0078	0.0087	0.0087	0.0085	0.0096	0.00866
F1	0.0014	0.0016	0.0016	0.0016	0.0017	0.00158
NDCG	0.0097	0.0098	0.0098	0.0097	0.0098	0.00976
I-Call	0.0424	0.0487	0.0455	0.0466	0.0466	0.04596



deepwalk algorithm & inner product  
number of walks = 200  
length of walk = 5  
dimension = 10  
n = 100

	1	2	3	4	5	Mean
Precision	0.0071	0.0069	0.0072	0.0073	0.0073	0.00716
Recall	0.0944	0.0945	0.0967	0.0994	0.0979	0.09658
F1	0.0125	0.0123	0.0127	0.013	0.0129	0.01268
NDCG	0	0	0	0	0	0
I-Call	0.422	0.4103	0.4167	0.422	0.0415	0.3425



deepwalk algorithm & cosine similarity


number of walks = 200

length of walk = 5

dimension = 10

n = 100

	1	2	3	4	5	Mean
Precision	0.0266	0.0258	0.0261	0.0269	0.0268	0.02644
Recall	0.3344	0.3244	0.3296	0.3346	0.3355	0.3317
F1	0.0468	0.0452	0.0459	0.0472	0.0471	0.04644
NDCG	0	0	0	0	0	0
I-Call	0.8472	0.8335	0.8398	0.8515	0.8494	0.84428



node2vec algorithm & inner product  
number of walks = 200  
length of walk = 5  
dimension = 10  
n = 100

	1	2	3	4	5	Mean
Precision	0.0021	0.0022	0.002	0.002	0.002	0.00206
Recall	0.0329	0.0341	0.0327	0.0295	0.03	0.03184
F1	0.0039	0.0039	0.0036	0.0036	0.0037	0.00374
NDCG	0	0	0	0	0	0
I-Call	0.176	0.1749	0.1643	0.158	0.1643	0.1675



node2vec algorithm & cosine similarity

number of walks = 200

length of walk = 5


dimension = 10

n = 100

	1	2	3	4	5	Mean
Precision	0.001	0.001	0.001	0.0009	0.0008	0.00094
Recall	0.0154	0.0172	0.0168	0.0152	0.0113	0.01518
F1	0.0018	0.0019	0.0018	0.0017	0.0014	0.00172
NDCG	0	0	0	0	0	0
I-Call	0.0922	0.0943	0.0954	0.0848	0.0721	0.08776




## مراجع

- Goyal, P., & Ferrara, E. (2018). Graph embedding techniques, applications, and performance: A survey. *Knowledge-Based Systems, 151*, 78–94.
  - Perozzi, B., Al-Rfou, R., & Skiena, S. (2014, August). Deepwalk: Online learning of social representations. In *Proceedings of the 20th ACM SIGKDD international conference on Knowledge discovery and data mining* (pp. 701–710).
  - Grover, A., & Leskovec, J. (2016, August). node2vec: Scalable feature learning for networks. In *Proceedings of the 22nd ACM SIGKDD international conference on Knowledge discovery and data mining* (pp. 855–864).
- 



## مراجع

- Cai, W., Pan, W., Liu, J., Chen, Z., & Ming, Z. (2020). k-Reciprocal nearest neighbors algorithm for one-class collaborative filtering. *Neurocomputing*, 381, 207–216.
- 



# با سپاس از توجه شما

شکایت طایفه